

Predicción de la capacidad de aprender a partir de características ambientales y conductuales en jóvenes mexicanos (10 - 17 años)

Ciencia de Datos Avanzada
Dra. Natalia Cadavid Aguilar

Adriana Ale Huesca - A01022013
Margarita Ojeda Hernández - A01797688
Omar Jacobo Tueme Márquez - A00959999

1. Introducción y Justificación del Problema

1.1 Definición del Problema

¿Cuál es el problema social específico?

La capacidad de aprender constituye un conjunto de habilidades cognitivas fundamentales para el desarrollo académico y profesional de las personas. Estas capacidades influyen directamente en indicadores como el rendimiento académico, la permanencia y terminación de estudios, así como en el desempeño laboral futuro. Su relevancia es particularmente alta durante la adolescencia, etapa en la que se consolidan procesos como la memoria, la atención, la autorregulación y la formación de hábitos que pueden influir en la trayectoria educativa y laboral a largo plazo.

Diversos estudios han documentado que las habilidades cognitivas en la adolescencia están fuertemente influenciadas por factores del entorno y por conductas individuales. En particular, el nivel socioeconómico, la exposición a violencia y las condiciones del hogar se asocian con el desarrollo cognitivo y el desempeño académico. Asimismo, factores conductuales y de salud como el consumo de sustancias, los trastornos de salud mental y los hábitos alimenticios influyen significativamente en procesos como la memoria, la atención y la capacidad de aprendizaje (World Health Organization, 2020; OECD, 2019; UNICEF, 2021).

La falta de entendimiento de cómo las características ambientales y conductuales influyen en la capacidad de aprender y recordar información, dificulta y limita las posibles intervenciones futuras que se puedan diseñar desde el ámbito público, escolar y familiar, que contribuyan a mejorar su desarrollo académico y bienestar futuro

¿En qué contexto ocurre?

El problema ocurre en la población adolescente en México (10 a 17 años), una etapa del desarrollo caracterizada por importantes cambios biológicos, psicológicos y sociales. Es un periodo en el que se consolidan habilidades cognitivas clave como la memoria, la atención y la capacidad de aprendizaje.

¿A quién afecta?

Afecta directamente a los adolescentes en México, particularmente a aquellos que enfrentan condiciones adversas en su entorno familiar o social. De manera indirecta, impacta a instituciones educativas, familias y al sistema de salud, al influir en el desarrollo de capital humano y en la demanda de futuros servicios sociales.

¿Por qué es relevante?

El problema es relevante porque la adolescencia es una etapa crítica del desarrollo en la que se consolidan habilidades cognitivas fundamentales como la memoria, la atención y la capacidad de aprendizaje. Estas habilidades influyen directamente en el rendimiento académico, la permanencia escolar y la conclusión de estudios, factores que a su vez impactan las oportunidades educativas y laborales futuras.

Se estima que, actualmente en México hay aproximadamente 17.2 millones de mexicanos con edad entre los 10 y 19 años.¹, los cuales se encuentran expuestos a distintos factores ambientales y conductuales como desigualdad socioeconómica, violencia, consumo de sustancias o problemas de salud que podrían afectar su desarrollo cognitivo. Comprender cómo estos factores se asocian con dificultades para aprender y recordar información es relevante porque permite:

- Identificar grupos en mayor situación de vulnerabilidad.
- Orientar políticas públicas en salud y educación.
- Diseñar intervenciones escolares y familiares más efectivas.
- Contribuir a reducir desigualdades educativas y sociales a largo plazo.

En términos de ciencia de datos, también es relevante porque permite utilizar evidencia cuantitativa para apoyar la toma de decisiones y priorizar recursos donde puedan tener mayor impacto.

1.2 Importancia social

Consecuencias de no resolver el problema.

Entre las principales consecuencias de no comprender ni atender la influencia de los factores ambientales y conductuales en el desarrollo cognitivo de los adolescentes, se encuentran:

1. Bajo rendimiento académico, que limita el aprendizaje significativo.
2. Mayor deserción escolar, reduciendo oportunidades educativas.
3. Reproducción de desigualdades sociales, al afectar más a jóvenes en contextos vulnerables.
4. Menores oportunidades laborales futuras, vinculadas a trayectorias educativas truncas.
5. Aumento de conductas de riesgo, asociadas a la falta de éxito escolar y exclusión social.

¹ https://www.inegi.org.mx/contenidos/programas/ccpv/2020/doc/Censo2020_piramide.pdf

6. Uso ineficiente de recursos públicos, al no focalizar intervenciones en poblaciones de mayor riesgo.

Impacto potencial del modelo.

El desarrollo de un modelo predictivo permitirá identificar patrones y factores asociados a la capacidad de aprendizaje y memoria en adolescentes, generando evidencia cuantitativa útil para la toma de decisiones. El impacto potencial incluye:

- Identificación temprana de adolescentes en situación de riesgo cognitivo.
- Priorización de intervenciones educativas, de salud y sociales.
- Diseño de programas preventivos basados en evidencia.
- Optimización del uso de recursos públicos mediante focalización.
- Generación de conocimiento útil para políticas públicas en educación y salud.

Actores que utilizarán los resultados.

- Instituciones educativas: Para diseñar estrategias de apoyo académico y prevención del rezago escolar.
- Autoridades educativas: Para orientar políticas públicas y programas de permanencia escolar.
- Sector salud: Para identificar factores conductuales y de salud asociados al desarrollo cognitivo.
- Gobiernos locales y federal: Para focalizar programas sociales en población adolescente vulnerable.
- Familias y comunidad escolar: Para promover entornos favorables para el aprendizaje.
- Organizaciones de la sociedad civil: Para diseñar intervenciones comunitarias dirigidas a jóvenes.

1.3 Objetivos

Objetivo general

Desarrollar un modelo predictivo que estime la capacidad de aprender y recordar información en adolescentes de 10 a 17 años en México, a partir de características ambientales y conductuales, con el fin de identificar factores de riesgo y generar evidencia que apoye la toma de decisiones en educación, salud y políticas públicas.

Objetivos específicos

- Identificar y seleccionar variables ambientales y conductuales asociadas con la capacidad de aprendizaje y memoria en adolescentes.

- Analizar la relación entre factores socioeconómicos, condiciones del entorno, salud y conductas individuales con el desempeño cognitivo.
- Determinar la importancia relativa de los factores que más influyen en el desempeño cognitivo.
- Generar evidencia que permita orientar intervenciones focalizadas en población adolescente en situación de riesgo.

Decisiones concretas que informará el modelo.

El modelo podrá apoyar decisiones como:

- Diseñar intervenciones de salud preventiva (nutrición, sueño, consumo de sustancias).
- Implementar programas de prevención de violencia en entornos con alto impacto cognitivo.
- Priorizar recursos públicos en zonas con mayor vulnerabilidad cognitiva.

2. Estado Actual y Brecha

2.1 ¿Cómo se aborda actualmente el problema?

Actualmente, el problema se aborda principalmente a través de 3 frentes: (i) Evaluaciones educativas estandarizadas, pruebas como PLANEA (antes ENLACE) y evaluaciones como PISA para medir el desempeño en lectura y matemáticas. Estas pruebas permiten identificar los logros académicos y brecha educativas. Sin embargo, no miden directamente las capacidades cognitivas como memoria o aprendizaje. (ii) Enfoques psicológicos, pruebas psicométricas aplicadas por especialistas y diagnósticos individuales. (iii) Políticas públicas educativas y sociales, programas de becas en distintas delegaciones, programas de alimentación escolar, prevención de adicciones etc.

2.2 Limitaciones de enfoques existentes

Los enfoques existentes presentan limitaciones importantes. En primer lugar, suelen ser reactivos y no preventivos, ya que las intervenciones se implementan cuando el bajo rendimiento académico ya es evidente. Además, muchos estudios utilizan análisis univariados o descriptivos, examinando factores de manera aislada, como únicamente el nivel socioeconómico. También existe una falta de integración de múltiples dimensiones, pues los factores ambientales, conductuales y de salud suelen analizarse por separado, aunque en la práctica interactúan entre sí; por ejemplo, la combinación de bajo nivel socioeconómico,

exposición a violencia y consumo de alcohol podría generar un efecto conjunto mayor que cada factor individual. A esto se suma la escasa focalización basada en riesgo cuantitativo, ya que muchas políticas públicas se aplican de forma generalizada sin priorizar según la probabilidad estimada de afectación cognitiva. Finalmente, las evaluaciones psicométricas profundas presentan limitaciones de escalabilidad.

2.3 Valor agregado del aprendizaje automático

El aprendizaje automático aporta un valor agregado significativo frente a los enfoques tradicionales al permitir modelar relaciones no lineales y capturar interacciones complejas entre variables que difícilmente pueden identificarse mediante métodos estadísticos convencionales. Además, facilita la integración simultánea de múltiples dimensiones —socioeconómicas, de salud, conductas de riesgo, condiciones del hogar y contexto comunitario— dentro de un mismo modelo analítico. Esto permite estimar probabilidades individuales de baja capacidad de aprendizaje y memoria, clasificar a los adolescentes en niveles de riesgo e impulsar intervenciones preventivas antes de que se manifiesten problemas como el bajo rendimiento o la deserción escolar.

3. Datos y Análisis Exploratorio

3.1 Descripción de los datos

Fuente.

ENSANUT Continua 2024, Cuestionario de salud de adolescentes (10 a 19 años).

Periodo temporal.

Datos de corte transversal del año 2024.

Unidad de análisis.

Cada registro es a nivel persona (1 renglón = 1 persona).

Número de observaciones.

En la base de datos original se cuenta con 3,730 observaciones únicas.

Variables disponibles.

La ENSANUT cuenta con cientos de columnas, sin embargo para propósitos de este análisis se decide quedarse con exclusivamente 53 columnas que abarcan temas relacionados a consumo de sustancias / drogas, enfermedades crónicas, salud mental, entre otros.

3.2 Limpieza y preparación

Tratamiento de valores faltantes.

El tratamiento de valores faltantes más significativo que se realizó fue la eliminación de todas las observaciones que no tenían ningún registro de la variable objetivo (dificultad de aprender) lo cual redujo la cantidad de observaciones de 3,730 a 3,040 (se eliminaron 690 registros). A lo largo del resto de la limpieza se fueron eliminando otros registros particularmente por que se asume que hubo error en la captura de algunos registros. Ésto redujo el tamaño total de la base de datos de los anteriores 3,040 a 3,010 (una reducción adicional de 30 observaciones).

Manejo de outliers.

Dado que ninguna de las variables es continua, no se cuenta con variables outliers.

Transformaciones realizadas.

La totalidad de las 53 variables con las que nos quedamos para el análisis de datos son categóricas ordinales. La variable objetivo la convertimos en una variable dicotómica en donde las personas con aunque sea algo de dificultad para aprender se les asigna 1 y las personas que no tienen ninguna dificultad se les asigna un 0. A pesar de esta decisión, terminamos con una muestra desbalanceada en donde 2,461 de los registros iniciales decían no tener ninguna dificultad y solo 579 decían tener alguna dificultad. Respecto a las variables predictoras, para mantener la riqueza de las respuestas se va a trabajar con una escala que va del 0 al 1. El propósito de dicha escala en comparación a, por ejemplo, del 0 al 10, es para poder mantener todas las variables con un valor entre 0 y 1 lo que nos ahorrará el paso del escalamiento de variables más adelante para poder utilizarlas en el KNN.

Se reconoce que es imposible saber, en una escala del 0 al 1, que tan seguido es "algunos días?" es por lo que se optó por espaciar las respuestas de manera igual. En casos de tener una escala de tres respuestas, el valor se irá aumentando en 0.5 ($0.0 \rightarrow 0.5 \rightarrow 1$).

Ingeniería de variables.

Al finalizar la limpieza y preparación de datos nos quedamos con una base de datos general con 3,010 observaciones y 23 variables incluyendo la variable objetivo. Se logró reducir la cantidad de variables de 53 a 23 mediante la agrupación de variables con alta similitud. Por ejemplo, las preguntas “¿Con qué frecuencia en los últimos 3 meses... te ha preocupado engordar? / en ocasiones, has comido demasiado? / has perdido el control sobre lo que comes? / has vomitado después de comer para bajar de peso? / etc.” se colapsaron en una sola variable que explica desórdenes alimenticios.

Adicional a ello, en la base descrita arriba existían aún variables con valores null en ciertas observaciones por cómo se capturó la información. Es por ello que al concluir la limpieza y preparación de datos obtenemos tres bases de datos:

- Una base de datos de niños de 10 y 11 años con 795 observaciones y 11 variables, incluyendo la variable objetivo.
- Una base de datos de jóvenes varones de 12 a 17 años con 1,124 observaciones y 19 de variables, incluyendo la variable objetivo.
- Una base de datos de jóvenes mujeres de 12 a 17 años con 1,091 observaciones y 19 variables, incluyendo la variable objetivo.

La reducción de variables en cada una de las bases de datos finales es debido a la sustracción de variables con muy pocas observaciones ($< 5\%$ de la cantidad de observaciones con un 1 en la variable objetivo)

3.3 Análisis exploratorio de datos (EDA)

Estadísticas descriptivas.

Dado que las variables construidas son escalas y no son continuas, lo que buscamos es comparar los promedios entre la muestra total y la muestra con dificultad para aprender. Al realizar la diferencia de promedios, observamos que en la muestra de niños entre 10 y 11 años las variables que aumentan en la submuestra de niños con dificultad para aprender son:

- Ansiedad
- Depresión
- Dificultad de concentración

Para la muestra de jóvenes varones entre 12 y 17 años las variables que aumentan son:

- Depresión
- Dificultad de concentración

Y por último, para la muestra de jóvenes mujeres entre 12 y 17 años las variables que aumentan son:

- Depresión
- Dificultad de concentración
- Desordenes alimenticios

Distribuciones de variables clave.

Dado que las variables no son continuas, no se aprende mucho de ver cómo se distribuyen las variables.

Correlaciones.

Al correr los análisis de correlación para las 3 bases de datos se puede observar una débil correlación entre las variables predictoras y nuestra variable objetivo. Consistentemente la variable que se encuentra más correlacionada es “Dificultad de concentración” con valores de 0.28, 0.22 y 0.28 en las bases de niños de 10 y 11 años, varones de 12 a 17 años y mujeres de 12 a 17 años respectivamente.


Fuera de la variable objetivos, se observan las más altas correlaciones en los siguientes casos:

- Ansiedad y depresión en niños de 10 y 11 años (0.45)
- Fumar y consumir drogas ilícitas en varones de 12 a 17 años (0.49)
- Ansiedad y depresión en varones de 12 a 17 años (0.50)
- Colesterol alto y triglicéridos altos en mujeres de 12 a 17 años (0.51)
- Ansiedad y depresión en mujeres de 12 a 17 años (0.55)

Visualizaciones interpretadas.


Dado que las variables no son continuas, no se puede observar mucho de manera gráfica con *sns.pairplot* como se lograría con variables continuas. Sin embargo, se preparó visualizaciones comparando el promedio del valor de cada uno de los predictores entre la muestra con dificultad de aprender y la muestra sin dificultad de aprender

Niños de 10 y 11 años de edad




- Se observan significativamente mayores niveles de ansiedad, depresión y dificultad de concentración en la muestra con dificultad para aprender.

Adolescentes varones de 12 a 17 años de edad



- Se observan significativamente mayores niveles de drogas ilícitas, depresión, dificultad de concentración, desórdenes alimenticios y accidentes en la muestra con dificultad para aprender.

Adolescentes mujeres de 12 a 17 años de edad



- Se observan significativamente mayores niveles de ansiedad, depresión, dificultad de concentración, dormir mal, pensamientos suicidas, desórdenes alimenticios y acoso sexual en la muestra con dificultad para aprender.

Identificación de patrones y posibles sesgos.

Se reconoce que hay un desbalance de clases de la variable objetivo (185 de 795 - 23% para los niños de 10 y 11 años; 186 de 1,124 - 17% para varones entre 12 y 17 años; 203 de 1,091 - 19% para mujeres entre 12 y 17 años) lo cual potencialmente puede sesgar los modelos que se harán a continuación. Adicionalmente a ello, se puede observar la relevancia

de la ansiedad, la depresión y la dificultad de concentración sobre cualquier otra variables como posibles predictores de la dificultad para aprender.

4. Definición del Problema de Aprendizaje Automático

4.1 Tipo de problema

Clasificación.

El problema planteado corresponde a un problema de **clasificación supervisada binaria**, cuyo objetivo es predecir si un adolescente presenta o no dificultades para aprender y recordar información.

Se trata de un problema supervisado debido a que se cuenta con una variable objetivo previamente observada en los datos (dificultad de aprendizaje), y el modelo busca aprender la relación entre esta variable y un conjunto de variables predictoras ambientales, conductuales y de salud. Es binario porque la variable objetivo fue transformada en dos categorías: presencia (1) o ausencia (0) de dificultad.

Este enfoque es consistente con el objetivo del proyecto de identificar individuos en riesgo, lo cual permite generar intervenciones focalizadas basadas en probabilidades de pertenencia a una clase.

4.2 Variable objetivo

Definición precisa.

La variable objetivo es la **dificultad para aprender y recordar información**, medida a partir de la percepción reportada por los adolescentes en la encuesta ENSANUT 2024.

Se define como una variable dicotómica:

- **1**: el adolescente presenta alguna dificultad para aprender o recordar.
- **0**: el adolescente no presenta ninguna dificultad.

Método de construcción.

La variable fue construida a partir de una variable original categórica ordinal, la cual fue transformada en binaria bajo el siguiente criterio:

- Cualquier nivel de dificultad (aunque sea leve) se codificó como **1**.
- La ausencia total de dificultad se codificó como **0**.

Justificación conceptual.

La construcción de la variable objetivo responde a la necesidad de identificar de manera temprana a adolescentes en situación de riesgo cognitivo. Desde un enfoque de

política pública y salud preventiva, resulta más relevante distinguir entre presencia y ausencia de dificultad que capturar niveles finos de severidad, ya que:

- Permite priorizar intervenciones.
- Facilita la interpretación de resultados.
- Es consistente con el objetivo de clasificación de riesgo.

Limitaciones.

- **Pérdida de información:** al convertir una variable ordinal en binaria, se pierde la variabilidad en la intensidad de la dificultad.
- **Subjetividad:** la variable proviene de autorreporte, lo cual puede introducir sesgos de percepción.
- **Desbalance de clases:** como se observa en la sección 3.3 (página 9), existe una proporción menor de casos positivos (entre 17% y 23%), lo que puede afectar el desempeño del modelo.
- **No mide capacidad cognitiva objetiva:** la variable refleja percepción, no pruebas estandarizadas.

4.3 Variables predictoras

Lista explícita de variables utilizadas.

A partir del proceso de limpieza e ingeniería de variables, se seleccionaron variables agrupadas en las siguientes dimensiones:

- **Salud mental y cognitiva:** Ansiedad, depresión y dificultad de concentración.
- **Conductas de riesgo:** Consumo de alcohol, consumo de tabaco y uso de drogas ilícitas.
- **Salud física:** Dormir mal, enfermedades crónicas (hipertensión, colesterol, triglicéridos, etc.)
- **Conductas alimentarias:** Desórdenes alimenticios.
- **Factores sociales y de entorno:** Exposición a violencia (robo, agresión), Acoso sexual, Accidentes.
- **Variables demográficas:** Edad, Sexo (implícito en la segmentación de bases).

Cabe destacar que el conjunto final de variables varía ligeramente entre las tres bases (niños, hombres y mujeres), debido a la disponibilidad y calidad de los datos.

Justificación teórica.

La selección de variables se fundamenta en evidencia teórica y empírica que sugiere que la capacidad de aprendizaje está influida por múltiples dimensiones:

- **Salud mental:** la ansiedad y la depresión afectan procesos cognitivos como la memoria y la atención.
- **Funciones cognitivas:** la dificultad de concentración es un predictor directo del aprendizaje.
- **Conductas de riesgo:** el consumo de sustancias puede afectar el funcionamiento neurológico.
- **Salud física y sueño:** dormir mal impacta la consolidación de la memoria.
- **Entorno social:** la exposición a violencia y estrés crónico afecta el desarrollo cognitivo.

Esto es consistente con lo descrito en la sección 1 del documento, donde se plantea un enfoque multidimensional del problema.

Evidencia empírica del EDA.

El análisis exploratorio (sección 3.3) proporciona evidencia clara sobre la relevancia de ciertas variables:

- En las tres poblaciones analizadas, destacan:
 - **Depresión**
 - **Dificultad de concentración**
- En niños (10–11 años):
 - La ansiedad también muestra diferencias importantes.
- En mujeres:
 - Desórdenes alimenticios, dormir mal y pensamientos suicidas son relevantes.

Además, la variable **dificultad de concentración** presenta la mayor correlación con la variable objetivo (hasta 0.28).

Variables descartadas y razones.

Durante la limpieza y preparación de datos se descartaron 30 variables, pasando de 53 a 23 variables, por las siguientes razones:

- **Alta proporción de valores faltantes:** variables con poca disponibilidad de datos.
- **Baja variabilidad:** variables con muy pocos casos positivos (<5%).
- **Redundancia conceptual:** variables similares fueron agrupadas (por ejemplo, múltiples preguntas sobre conductas alimentarias).
- **Inconsistencias en captura:** registros eliminados por posibles errores.

Tratamiento de colinealidad.

El análisis de correlación muestra algunas relaciones moderadas entre variables predictoras, por ejemplo:

- Ansiedad y depresión (hasta 0.55)
- Consumo de tabaco y drogas ilícitas (~0.49)

Para abordar la colinealidad se realizó una agrupación **de variables altamente relacionadas** durante la ingeniería de variables y se priorizó la **interpretabilidad** sobre la inclusión de variables redundantes. Dado que las correlaciones no son extremadamente altas, no se considera un problema severo, pero sí un aspecto a monitorear.

5. Modelos y Algoritmos

5.1 Modelo baseline - árbol de decisión

Descripción técnica.

Modelo que divide el espacio de los predictores de forma jerárquica mediante decisiones binarias sucesivas, construyendo un árbol de reglas hasta llegar a una clasificación.

Supuestos.

Asume que los datos tienen una estructura jerárquica y que las decisiones se pueden representar como splits binarios en cada nodo.

Ventajas y desventajas.

Es altamente interpretable y no requiere normalización de datos. Sin embargo, es muy propenso al sobreajuste y sensible al desbalance de clases.

Riesgo de sobreajuste.

Muy alto, se controla limitando la profundidad máxima del árbol.

Nivel de interpretabilidad.

Alta, el árbol puede visualizarse y cada decisión es trazable.

Justificación en el contexto social.

Permite comunicar de forma clara a tomadores de decisiones (escuelas, familias, políticas públicas) qué factores llevan a una disminución en la capacidad para aprender, haciendo el modelo auditable y comprensible para actores no técnicos.

5.2 Modelo baseline - regresión logística

Descripción técnica.

Modelo lineal que estima la probabilidad de pertenencia a una clase usando la función sigmoide sobre una combinación lineal de los predictores.

Supuestos.

Asume una relación lineal entre los predictores y el log-odds de la clase, y que la variable dependiente es dicotómica.

Ventajas y desventajas.

Muy interpretable y permite calcular probabilidades directamente. Su principal limitación es que solo captura relaciones lineales y es sensible a outliers.

Riesgo de sobreajuste.

Bajo, se controla con regularización L1 (Lasso) o L2 (Ridge).

Nivel de interpretabilidad.

Alta, el signo y magnitud de cada coeficiente indican dirección e impacto de cada uno de los predictores.

Justificación en el contexto social.

Similar al árbol, al producir probabilidades directamente interpretables y coeficientes por variable, permite identificar cuáles factores tienen mayor relevancia.

5.3 Modelo baseline - KNN

Descripción técnica.

Algoritmo no paramétrico que clasifica una persona nueva según la clase mayoritaria de sus K vecinos más cercanos en el espacio de los predictores.

Supuestos.

Asume que personas similares se encuentran cerca en el espacio métrico y que todas los predictores están en escalas comparables.

Ventajas y desventajas.

Es un lazy learner, lo que significa que no tiene fase de entrenamiento formal y es flexible. Por otra parte, la predicción es lenta en datasets grandes y requiere normalización previa.

Riesgo de sobreajuste.

Medio, un K muy pequeño genera sobreajuste; se controla ajustando el número de vecinos.

Nivel de interpretabilidad.

Baja-media, la decisión se explica por similitud con los vecinos, no por una fórmula explícita.

Justificación en el contexto social.

Útil para identificar perfiles de adolescentes similares en riesgo. Sin embargo, su baja transparencia limita su uso en contextos donde se deba justificar la decisión ante una institución.

5.4 Modelo intermedio - random forest

Descripción técnica.

Modelo de ensamble que entrena múltiples árboles de decisión independientes sobre subconjuntos aleatorios de datos (bootstrapping) y combina sus predicciones por votación.

Supuestos.

Asume que los árboles son suficientemente independientes entre sí gracias al muestreo aleatorio de datos y predictores.

Ventajas y desventajas.

Reduce considerablemente el sobreajuste de un árbol individual y no requiere normalización. Tiene como desventajas que requiere una mayor demanda computacional y tiene menor interpretabilidad.

Riesgo de sobreajuste.

Bajo, el mecanismo de bagging reduce la varianza del modelo.

Nivel de interpretabilidad.

Baja, se puede aproximar mediante “feature importance”, pero no existe una regla única trazable.

Justificación en el contexto social.

Su robustez ante datos desbalanceados lo hace adecuado para poblaciones vulnerables donde los datos pueden ser incompletos. Además, la “feature importance” permite orientar recursos públicos hacia los factores de mayor impacto.

5.5 Modelo intermedio - gradient boosting

Descripción técnica.

Modelo de ensamble secuencial que construye árboles de forma iterativa, donde cada árbol corrige los errores residuales del anterior optimizando una función de pérdida.

Supuestos.

Asume que los errores del modelo actual pueden reducirse de forma secuencial mediante la adición de nuevos árboles ajustados al gradiente de la pérdida.

Ventajas y desventajas.

Ofrece de los mayores poderes predictivos y permite alta personalización vía hiperparámetros. Sin embargo, es más lento de entrenar y el manejo de hiperparámetros puede derivar en sobreajuste.

Riesgo de sobreajuste.

Alto, se controla con regularización, learning rate bajo y limitando la profundidad de los árboles.

Nivel de interpretabilidad.

Baja, al igual que Random Forest, se apoya en “feature importance”.

Justificación en el contexto social.

Maximiza la capacidad predictiva; su precisión superior justifica la complejidad adicional. Se tiene que acompañar de herramientas como SHAP para mantener la transparencia.

6. Estrategia de Validación

6.1 División de datos

Entrenamiento / evaluación.

Se decide hacer una división 80 / 20 para nuestro entrenamiento y evaluación. El uso de ésta metodología es en particular para poder extraer “feature importances” y entender cuáles variables están usando los modelos.

Validación cruzada.

Se utiliza validación cruzada con 5 cortes para poder evaluar los modelos. Se confía más en los resultados de la validación cruzada dado que utiliza más cortes de la base de datos y no solo un corte que puede favorecer el modelo.

6.2 Métricas de evaluación


Métricas utilizadas.

Se evalúan las métricas de Accuracy, Precision, Recall, F1 y AUC. Sin embargo, dado el desbalance de clases, no se utiliza Accuracy para llegar a ninguna conclusión ya que puede estar inflada.

Resultados - Niños de 10 y 11 años.

	Decision Tree	KNN	Logistic Regression	Random Forest	XGBoost
Accuracy (CV)	0.698113	0.733333	0.664151	0.654088	0.647799
Precision (CV)	0.388927	0.391455	0.360286	0.349001	0.329633
Recall (CV)	0.508108	0.227027	0.551351	0.556757	0.475676
F1 (CV)	0.440378	0.284468	0.435064	0.428575	0.386368
AUC (CV)	0.677581	0.541626	0.661808	0.676119	0.585999

DECISION TREE




- “Mejores” modelos son el árbol, la regresión logística y el random forest.
- Sin embargo, no son buenos.
 - AUC ~ 0.67 (mejor que una moneda, pero no es bueno).
 - Precision ~ 0.36 (de las predicciones, 36% son acertadas).
 - Recall ~ 0.52 (de los niños que necesitan ayuda, solo se identifica 52%).
- La decisión colapsa a solo 2 variables (dificultad de concentración y depresión).

Resultados - Adolescentes varones de 12 a 17 años.

	Decision Tree	KNN	Logistic Regression	Random Forest	XGBoost
Accuracy (CV)	0.690325	0.741139	0.682345	0.709937	0.707266
Precision (CV)	0.284028	0.243467	0.265591	0.288224	0.255627
Recall (CV)	0.554054	0.263442	0.516074	0.510811	0.381935
F1 (CV)	0.374141	0.252769	0.349718	0.368104	0.304378
AUC (CV)	0.673289	0.549647	0.647874	0.674345	0.585728

DECISION TREE




- “Mejor” modelo es el árbol.
- Sin embargo, no son buenos.
 - AUC ~ 0.67 (mejor que una moneda, pero no es bueno).
 - Precision ~ 0.28 (de las predicciones, 28% son acertadas).
 - Recall ~ 0.55 (de los jóvenes que necesitan ayuda, solo se identifica 55%).
- Dificultad de concentración sigue dominando, pero ya hay más variables.

Resultados - Adolescentes mujeres de 12 a 17 años.

	Decision Tree	KNN	Logistic Regression	Random Forest	XGBoost
Accuracy (CV)	0.627812	0.810268	0.701219	0.662691	0.703046
Precision (CV)	0.287487	0.452576	0.328704	0.307064	0.311752
Recall (CV)	0.655244	0.118293	0.581341	0.645244	0.492439
F1 (CV)	0.398197	0.186372	0.418534	0.415395	0.380973
AUC (CV)	0.672487	0.656171	0.726080	0.718902	0.666941

LOGISTIC REGRESSION



- “Mejores” modelos son la regresión logística y el random forest.
- Mejor que los anteriores, pero no el mejor.
 - AUC ~ 0.72 (5% mejor que los anteriores).
 - Precision ~ 0.32 (de las predicciones, 32% son acertadas).
 - Recall ~ 0.62 (de los jóvenes que necesitan ayuda, se identifica 62%).
- Se encuentran predictores contraintuitivos. Por ejemplo el consumo de drogas ilícitas con un gran coeficiente negativo.

7. Consideraciones Éticas

7.1 Privacidad

El análisis se basa en datos provenientes de la ENSANUT 2024, los cuales están anonimizados y no contienen información que permita identificar directamente a los individuos.

7.2 Sesgo algorítmico

El modelo puede incorporar o amplificar sesgos presentes en los datos. En este caso, existen dos fuentes principales de sesgo:

- **Desbalance de clases:** como se observa en el EDA, la proporción de adolescentes con dificultad de aprendizaje es menor (17%–23%), lo que puede llevar al modelo a favorecer a la clase mayoritaria.
- **Sesgo de medición:** la variable objetivo es autoreportada, lo que puede introducir diferencias sistemáticas en la forma en que distintos grupos perciben o reportan sus dificultades.

Asimismo, ciertas variables (por ejemplo, condiciones socioeconómicas o exposición a violencia) pueden reflejar desigualdades estructurales, lo que podría generar predicciones sesgadas hacia ciertos grupos.

7.3 Discriminación indirecta

Aunque el modelo no utilice explícitamente variables sensibles como nivel socioeconómico o género en todos los casos, algunas variables predictoras pueden actuar como **proxies** de estas características. Esto puede derivar en **discriminación indirecta**, por ejemplo:

- Etiquetar sistemáticamente como “alto riesgo” a adolescentes de contextos vulnerables.

- Reforzar estigmas asociados a pobreza, salud mental o conductas de riesgo.

7.4 Transparencia e interpretabilidad

La transparencia e interpretabilidad del modelo se abordará mediante la selección de algoritmos y herramientas que permitan comprender claramente cómo se generan las predicciones.

7.5 Rendición de cuentas

La rendición de cuentas es especialmente relevante cuando el modelo influye en políticas públicas o intervenciones dirigidas a población vulnerable. En particular:

- Las decisiones no deben recaer exclusivamente en el modelo.
- Las instituciones que lo utilicen deben asumir responsabilidad por su aplicación.

7.6 Estrategias de mitigación

Para reducir los riesgos éticos identificados, se proponen las siguientes estrategias:

- 1. Protección de datos:** Uso exclusivo de datos anonimizados, Restricción de acceso a información sensible.
- 2. Uso responsable.** Enfocar el modelo en la **prevención** y únicamente como **herramienta de apoyo** para focalizar intervenciones, así como comunicar claramente sus limitaciones.

8. Limitaciones

8.1 Limitaciones de datos

El análisis se basa en datos de la encuesta ENSANUT Continua 2024, los cuales presentan varias limitaciones relevantes. En primer lugar, se trata de datos de corte transversal, lo que impide observar dinámicas temporales o relaciones causales entre las variables. Asimismo, la variable objetivo, dificultad para aprender, es autoreportada, lo que introduce posibles sesgos de percepción y medición entre los adolescentes.

Adicionalmente, el proceso de limpieza implicó la eliminación de observaciones con valores faltantes, lo cual redujo el tamaño de la muestra y podría generar sesgos si los datos faltantes no son aleatorios. También se observa un desbalance de clases, donde la proporción de adolescentes con dificultades de aprendizaje es menor, lo que puede afectar el desempeño y la capacidad predictiva de los modelos.

8.2 Restricciones metodológicas

El enfoque metodológico presenta ciertas limitaciones inherentes. En primer lugar, la transformación de la variable objetivo a un formato binario simplifica el problema, pero elimina información sobre la intensidad de la dificultad de aprendizaje.

Adicionalmente, una limitación central del proyecto es que los predictores seleccionados no logran explicar de manera robusta la variable objetivo. Aunque modelos como Decision Tree, Logistic Regression y Random Forest presentan el mejor desempeño relativo, en términos absolutos ninguno alcanza un nivel adecuado de predicción, con métricas moderadas que limitan su aplicabilidad práctica.

Por otro lado, algunos modelos utilizados presentan menor interpretabilidad o riesgo de sobreajuste, y el desbalance de clases puede sesgar las predicciones hacia la categoría mayoritaria.

8.3 Supuestos realizados

Durante el desarrollo del modelo se realizaron varios supuestos que pueden influir en los resultados. En primer lugar, se asumió que las escalas construidas a partir de variables categóricas reflejan adecuadamente la intensidad de los fenómenos analizados, aun cuando no existe una equivalencia exacta entre categorías.

También se asumió que la variable autoreportada de dificultad para aprender es un proxy válido de la capacidad cognitiva real, aunque no corresponde a una medición objetiva.

Finalmente, se asume que las variables seleccionadas capturan de manera suficiente los factores relevantes, aunque es posible que existan variables omitidas que influyan significativamente en la capacidad de aprendizaje.

8.4 Problemas de generalización

En primer lugar, el análisis se basa en datos específicos de adolescentes mexicanos en 2024, por lo que los hallazgos podrían no ser extrapolables a otros contextos.

Asimismo, el tamaño de muestra efectivo se reduce al segmentar la población por sexo y grupos de edad, lo que genera submuestras relativamente pequeñas. Esto puede afectar la estabilidad de los modelos y aumentar la variabilidad de los resultados.

Finalmente, dado el desempeño moderado de los modelos, existe incertidumbre en su capacidad para generalizar a nuevos datos

9. Recomendaciones de Implementación

9.1 Cómo se usaría el modelo

El modelo se utilizaría como una herramienta de apoyo para la identificación temprana de adolescentes con mayor probabilidad de presentar dificultades en la capacidad de aprendizaje y memoria. Su implementación estaría orientada a instituciones educativas, autoridades de salud y tomadores de decisiones en políticas públicas.

En la práctica, el modelo recibiría como insumo información relacionada con características ambientales, conductuales y de salud de los adolescentes, y generaría una probabilidad estimada de riesgo. Esta probabilidad permitiría clasificar a los individuos en distintos niveles, facilitando la priorización de intervenciones.

Es importante destacar que el modelo no debe utilizarse como un mecanismo de diagnóstico individual ni como sustituto de evaluación profesional, sino como una herramienta complementaria para focalizar recursos y diseñar estrategias preventivas.

9.2 Decisiones concretas

El modelo se puede utilizar en distintos sectores:

Nivel Académico (escuelas):

Identificar estudiantes con mayor riesgo para canalizarlos a programas de apoyo académico o psicológico.

Diseñar estrategias de intervención enfocadas en factores relevantes como salud mental, hábitos de sueño o conductas de riesgo.

Nivel de política pública:

Priorizar recursos en regiones o poblaciones con mayor concentración de riesgo.

Diseñar programas preventivos en salud mental, nutrición o prevención de adicciones.

Nivel comunitario y familiar:

Promover campañas de concientización sobre factores que afectan el aprendizaje.

Fortalecer entornos familiares y escolares que favorezcan el desarrollo cognitivo.

9.3 Propuesta de piloto o evaluación futura

Se propone implementar un Piloto Controlado, antes de escalar el modelo y dividirlo en 3 Fases:

Fase 1: Piloto

Aplicación en un conjunto pequeño de escuelas

Validación con profesionales

Fase 2: Evaluación

Comparar:

Casos detectados por el modelo vs métodos tradicionales

Precisión en la identificación de estudiantes con dificultades

Evaluar aceptación por: escuelas, familias y personal de salud

Fase 3: Iteración

Ajustar: variables, definición de variable objetivo y umbrales de decisión

9.4 Indicadores de impacto

Los indicadores de impacto se agrupan en tres dimensiones principales. En términos de desempeño del modelo, se evaluarán métricas como AUC, Precision, Recall y F1, así como la calibración del score y su estabilidad en el tiempo. En cuanto a la eficiencia operativa, se considerará el porcentaje de casos correctamente priorizados, la reducción en el tiempo de identificación de casos y la mejora en la focalización de recursos. Finalmente, en el ámbito de impacto social, se medirá la mejora en el desempeño académico y el bienestar emocional de los adolescentes. No obstante, dado que los resultados sugieren que los predictores actuales tienen bajo poder discriminativo, el impacto del modelo dependerá en mayor medida de la mejora en la calidad de los datos que del uso de modelos más complejos.

Referencias

1. OECD (2019). PISA Results.
2. UNICEF (2021). The State of the World's Children.
3. Bradley & Corwyn (2002). Socioeconomic Status and Child Development.
4. World Health Organization (2020). *Adolescent Mental Health*.
5. Shonkoff et al. (2012). *Toxic Stress and Development*