

**Predicción de la capacidad de aprender utilizando características ambientales y
conductuales de jóvenes (10 - 17 años) en México**

Ciencia de datos avanzada

Dra. Natalia Cadavid Aguilar

Adriana Ale Huesca - A01022013

Margarita Ojeda Hernández - A01797688

Omar Jacobo Tueme Márquez - A00959999

Introducción y justificación del problema

Definición del problema

Nombre del problema.

Predicción de la capacidad de aprender utilizando características ambientales y conductuales de jóvenes (10 - 17 años) en México

¿Cuál es el problema social específico?

La capacidad de aprender constituye un conjunto de habilidades cognitivas fundamentales para el desarrollo académico y profesional de las personas. Estas capacidades influyen directamente en indicadores como el rendimiento académico, la permanencia y terminación de estudios, así como en el desempeño laboral futuro. Su relevancia es particularmente alta durante la adolescencia, etapa en la que se consolidan procesos como la memoria, la atención, la autorregulación y la formación de hábitos que pueden influir en la trayectoria educativa y laboral a largo plazo.

Diversas fuentes de información sugieren que estas habilidades cognitivas pueden verse influenciadas por factores del entorno y por conductas individuales. Entre las características ambientales se encuentran el nivel socioeconómico del hogar (medido a través del índice de bienestar), la exposición a violencia y las condiciones materiales del hogar. Por otro lado, las características conductuales y de salud incluyen el consumo de alcohol y drogas, la presencia de enfermedades crónicas y las conductas alimentarias.

La falta de entendimiento de cómo las características ambientales y conductuales influyen en la capacidad de aprender y recordar información, dificulta y limita las posibles intervenciones futuras que se puedan diseñar desde el ámbito público, escolar y familiar, que contribuyan a mejorar su desarrollo académico y bienestar futuro

¿En qué contexto ocurre?

El problema ocurre en la población adolescente en México (10 a 17 años), una etapa del desarrollo caracterizada por importantes cambios biológicos, psicológicos y sociales. Es un periodo en el que se consolidan habilidades cognitivas clave como la memoria, la atención y la capacidad de aprendizaje.

¿A quién afecta?

Jóvenes (10 a 17 años de edad) en México. Se estima que actualmente en México hay aproximadamente 17.2 millones de mexicanos con edad entre los 10 y 19 años (https://www.inegi.org.mx/contenidos/programas/ccpv/2020/doc/Censo2020_piramide.pdf)

¿Por qué es relevante?

El problema es relevante porque la adolescencia es una etapa crítica del desarrollo en la que se consolidan habilidades cognitivas fundamentales como la memoria, la atención y la capacidad de aprendizaje. Estas habilidades influyen directamente en el rendimiento académico, la permanencia escolar y la conclusión de estudios, factores que a su vez impactan las oportunidades educativas y laborales futuras.

En México, millones de adolescentes se encuentran expuestos a distintos factores ambientales y conductuales como desigualdad socioeconómica, violencia, consumo de sustancias o problemas de salud que podrían afectar su desarrollo cognitivo. Comprender si y cómo estos factores se asocian con dificultades para aprender y recordar información es relevante porque permite:

- Identificar grupos en mayor situación de vulnerabilidad.
- Orientar políticas públicas en salud y educación.
- Diseñar intervenciones escolares y familiares más efectivas.
- Contribuir a reducir desigualdades educativas y sociales a largo plazo.

En términos de ciencia de datos, también es relevante porque permite utilizar evidencia cuantitativa para apoyar la toma de decisiones y priorizar recursos donde puedan tener mayor impacto.

Importancia social

Consecuencias de no resolver el problema.

Entre las principales consecuencias de no comprender ni atender la influencia de los factores ambientales y conductuales en el desarrollo cognitivo de los adolescentes, se encuentran:

- Bajo rendimiento académico, que limita el aprendizaje significativo.
- Mayor deserción escolar, reduciendo oportunidades educativas.
- Reproducción de desigualdades sociales, al afectar más a jóvenes en contextos vulnerables.
- Menores oportunidades laborales futuras, vinculadas a trayectorias educativas truncas.
- Aumento de conductas de riesgo, asociadas a la falta de éxito escolar y exclusión social.
- Uso ineficiente de recursos públicos, al no focalizar intervenciones en poblaciones de mayor riesgo.

Impacto potencial del modelo.

El desarrollo de un modelo predictivo permitirá identificar patrones y factores asociados a la capacidad de aprendizaje y memoria en adolescentes, generando evidencia cuantitativa útil para la toma de decisiones. El impacto potencial incluye:

- Identificación temprana de adolescentes en situación de riesgo cognitivo.
- Priorización de intervenciones educativas, de salud y sociales.
- Diseño de programas preventivos basados en evidencia.
- Optimización del uso de recursos públicos mediante focalización.
- Generación de conocimiento útil para políticas públicas en educación y salud.

Actores que utilizarán los resultados.

- Instituciones educativas: Para diseñar estrategias de apoyo académico y prevención del rezago escolar.
- Autoridades educativas: Para orientar políticas públicas y programas de permanencia escolar.
- Sector salud: Para identificar factores conductuales y de salud asociados al desarrollo cognitivo.
- Gobiernos locales y federal: Para focalizar programas sociales en población adolescente vulnerable.
- Familias y comunidad escolar: Para promover entornos favorables para el aprendizaje.
- Organizaciones de la sociedad civil: Para diseñar intervenciones comunitarias dirigidas a jóvenes.

Objetivos

Objetivo general.

Desarrollar un modelo predictivo que estime la capacidad de aprender y recordar información en adolescentes de 10 a 17 años en México, a partir de características ambientales y conductuales, con el fin de identificar factores de riesgo y generar evidencia que apoye la toma de decisiones en educación, salud y políticas públicas.

Objetivos específicos.

- Identificar y seleccionar variables ambientales y conductuales asociadas con la capacidad de aprendizaje y memoria en adolescentes.
- Analizar la relación entre factores socioeconómicos, condiciones del entorno, salud y conductas individuales con el desempeño cognitivo.
- Determinar la importancia relativa de los factores que más influyen en el desempeño cognitivo.

- Generar evidencia que permita orientar intervenciones focalizadas en población adolescente en situación de riesgo.

Decisiones concretas que informará el modelo.

El modelo podrá apoyar decisiones como:

- Diseñar intervenciones de salud preventiva (nutrición, sueño, consumo de sustancias).
- Implementar programas de prevención de violencia en entornos con alto impacto cognitivo.
- Priorizar recursos públicos en zonas con mayor vulnerabilidad cognitiva.

Estado actual y brecha

¿Cómo se aborda actualmente el problema?

Actualmente, el problema se aborda principalmente a través de 3 frentes: (i) Evaluaciones educativas estandarizadas, pruebas como PLANEA (antes ENLACE) y evaluaciones como PISA para medir el desempeño en lectura y matemáticas. Estas pruebas permiten identificar los logros académicos y brecha educativas. Sin embargo, no miden directamente las capacidades cognitivas como memoria o aprendizaje. (ii) Enfoques psicológicos, pruebas psicométricas aplicadas por especialistas y diagnósticos individuales. (iii) Políticas públicas educativas y sociales, programas de becas en distintas delegaciones, programas de alimentación escolar, prevención de adicciones etc.

Limitaciones de enfoques existentes

Los enfoques existentes presentan limitaciones importantes. En primer lugar, suelen ser reactivos y no preventivos, ya que las intervenciones se implementan cuando el bajo rendimiento académico ya es evidente. Además, muchos estudios utilizan análisis univariados o descriptivos, examinando factores de manera aislada, como únicamente el nivel socioeconómico. También existe una falta de integración de múltiples dimensiones, pues los factores ambientales, conductuales y de salud suelen analizarse por separado, aunque en la práctica interactúan entre sí; por ejemplo, la combinación de bajo nivel socioeconómico, exposición a violencia y consumo de alcohol podría generar un efecto conjunto mayor que cada factor individual. A esto se suma la escasa focalización basada en riesgo cuantitativo, ya que muchas políticas públicas se aplican de forma generalizada sin priorizar según la probabilidad estimada de afectación cognitiva. Finalmente, las evaluaciones psicométricas profundas presentan limitaciones de escalabilidad.

Valor agregado del aprendizaje automático

El aprendizaje automático aporta un valor agregado significativo frente a los enfoques tradicionales al permitir modelar relaciones no lineales y capturar interacciones complejas entre variables que difícilmente pueden identificarse mediante métodos estadísticos convencionales. Además, facilita la integración simultánea de múltiples dimensiones —socioeconómicas, de salud, conductas de riesgo, condiciones del hogar y contexto comunitario— dentro de un mismo modelo analítico. Esto permite estimar probabilidades individuales de baja capacidad de aprendizaje y memoria, clasificar a los adolescentes en niveles de riesgo e impulsar intervenciones preventivas antes de que se manifiesten problemas como el bajo rendimiento o la deserción escolar.

Datos y análisis exploratorio

Descripción de los datos

Fuente.

ENSANUT Continua 2024, Cuestionario de salud de adolescentes (10 a 19 años).

Periodo temporal.

Datos de corte transversal del año 2024.

Unidad de análisis.

Cada registro es a nivel persona (1 renglón = 1 persona).

Número de observaciones.

En la base de datos original se cuenta con 3,730 observaciones únicas.

Variables disponibles.

La ENSANUT cuenta con cientos de columnas, sin embargo para propósitos de este análisis se decide quedarse con exclusivamente 53 columnas que abarcan temas relacionados a consumo de sustancias / drogas, enfermedades crónicas, salud mental, entre otros.

Limpieza y preparación

Tratamiento de valores faltantes.

El tratamiento de valores faltantes más significativo que se realizó fue la eliminación de todas las observaciones que no tenían ningún registro de la variable objetivo (dificultad de aprender) lo cual redujo la cantidad de observaciones de 3,730 a 3,040 (se eliminaron 690 registros). A lo largo del resto de la limpieza se fueron eliminando otros registros particularmente por que se asume que hubo error en la captura de algunos registros. Ésto redujo el tamaño total de la base de datos de los anteriores 3,040 a 3,010 (una reducción adicional de 30 observaciones).

Manejo de outliers.

Dado que ninguna de las variables es continua, no se cuenta con variables outliers.

Transformaciones realizadas.

La totalidad de las 53 variables con las que nos quedamos para el análisis de datos son categóricas ordinales. Dado que las escalas de las variables son diferentes, se decidió convertir las variables en variables dicotómicas aproximando el 0 a “no”, “nunca”, “casi nunca” y el 1 a “siempre”, “casi siempre”, “algunas veces”.

Ingeniería de variables.

Al finalizar la limpieza y preparación de datos nos quedamos con una base de datos general con 3,010 observaciones y 23 variables incluyendo la variable objetivo. Se logró reducir la cantidad de variables de 53 a 23 mediante la agrupación de variables con alta similitud. Por ejemplo, las preguntas “¿Con qué frecuencia en los últimos 3 meses... te ha preocupado engordar? / en ocasiones, has comido demasiado? / has perdido el control sobre lo que comes? / has vomitado después de comer para bajar de peso? / etc.” se condensaron en una sola variable que explica desórdenes alimenticios, siendo 1 que la persona ha presentado alguno de los síntomas muy frecuentemente (más de 2 veces en una semana) y 0 que la persona no presenta ninguno de los síntomas muy frecuentemente.

Adicional a ello, en la base descrita arriba existían aún variables con valores null en ciertas observaciones por cómo se capturó la información. Es por ello que al concluir la limpieza y preparación de datos obtenemos tres bases de datos:

- Una base de datos de niños de 10 y 11 años con 795 observaciones y 11 variables, incluyendo la variable objetivo.
- Una base de datos de jóvenes varones de 12 a 17 años con 1,124 observaciones y 19 de variables, incluyendo la variable objetivo.
- Una base de datos de jóvenes mujeres de 12 a 17 años con 1,091 observaciones y 19 variables, incluyendo la variable objetivo.

La reducción de variables en cada una de las bases de datos finales es debido a la sustracción de variables con muy pocas observaciones (< 5% de la cantidad de observaciones con un 1 en la variable objetivo)

Análisis exploratorio de datos (EDA)

Estadísticas descriptivas.

Dado que las variables construidas son dicotómicas, lo que buscamos es comparar los promedios entre la muestra total y la muestra con dificultad para aprender. Al realizar la

diferencia de promedios, observamos que en la muestra de niños entre 10 y 11 años las variables que aumentan en la submuestra de niños con dificultad para aprender son:

- Ansiedad
- Depresión
- Dificultad de concentración

Para la muestra de jóvenes varones entre 12 y 17 años las variables que aumentan son:

- Depresión
- Dificultad de concentración

Y por último, para la muestra de jóvenes mujeres entre 12 y 17 años si hay variables que tienen mayor representación en la muestra con dificultad para aprender, pero ninguna tan significativa como los anteriormente mencionados.

Distribuciones de variables clave.

Dado que las variables son dicotómicas, no se puede observar cómo se distribuyen las variables.

Correlaciones.

Al correr los análisis de correlación para las 3 bases de datos se puede observar una débil correlación entre las variables predictoras y nuestra variable objetivo. Consistentemente la variable que se encuentra más correlacionada es “Dificultad de concentración” con valores de 0.22, 0.18 y 0.22 en las bases de niños de 10 y 11 años, varones de 12 a 17 años y mujeres de 12 a 17 años respectivamente.


Fuera de la variable objetivos, se observan las más altas correlaciones en los siguientes casos:

- Ansiedad y depresión en niños de 10 y 11 años (0.33)
- Fumar y consumir drogas ilícitas en varones de 12 a 17 años (0.46)
- Colesterol alto y triglicéridos altos en mujeres de 12 a 17 años (0.51)

Visualizaciones interpretadas.


Dado que las variables son dicotómicas (con excepción de la edad) no se puede observar mucho de manera gráfica con *sns.pairplot* como se lograría con variables continuas. Sin embargo, se preparó visualizaciones de las proporciones de “aciertos” o de “sí” para cada una de las bases de datos

Niños de 10 y 11 años de edad




- Se observan significativamente mayores niveles de ansiedad, depresión y dificultad de concentración en la muestra con dificultad para aprender

Adolescentes varones de 12 a 17 años de edad



- Se observan significativamente mayores niveles de ansiedad, depresión, dificultad de concentración y accidentes en la muestra con dificultad para aprender

Adolescentes mujeres de 12 a 17 años de edad



- Se observan significativamente mayores niveles de ansiedad, depresión, dificultad de concentración, dormir mal, pensamientos suicidas y acoso sexual en la muestra con dificultad para aprender

Identificación de patrones y posibles sesgos.

Se reconoce que hay un desbalance de clases de la variable objetivo (185 de 795 - 23% para los niños de 10 y 11 años; 186 de 1,124 - 17% para varones entre 12 y 17 años; 203 de 1,091 - 19% para mujeres entre 12 y 17 años) lo cual potencialmente puede sesgar los modelos que se harán a continuación. Adicionalmente a ello, se puede observar la relevancia de la ansiedad, la depresión y la dificultad de concentración sobre cualquier otra variables como posibles predictores de la dificultad para aprender.

Referencias